




图卷积网络

托马斯·基普夫, 2016年9月30日



多层图卷积网络 (GCN) 采用一阶滤波器。

推特 0 分享

概述

许多重要的现实世界数据集以图或网络的形式存在：社交网络、知识图谱、蛋白质相互作用网络、万维网等（仅举几例）。然而，直到最近，神经网络模型推广到此类结构化数据集的关注仍然很少。

在过去几年里，许多论文重新探讨了将神经网络推广应用于任意结构图的问题（Bruna 等, ICLR 2014; Henaff 等, 2015; Duvenaud 等, NIPS 2015; Li 等, ICLR 2016; Defferrard 等, NIPS 2016; Kipf & Welling, ICLR 2017），其中一些现在在此前主要由核方法、基于图的正则化技术等主导的领域取得了非常有前景的成果。

在这篇文章中，我将简要概述该领域的最新发展，并指出各种方法的优缺点。这里的讨论主要将聚焦于两篇近期论文：

- Kipf & Welling (ICLR 2017) , [《带图卷积网络的半监督分类法》](#)（免责声明：我为第一作者）
- Defferrard 等人 (NIPS 2016) , [带快速局部频谱滤波的卷积神经网络图](#)

以及Ferenc Huszar的一篇评论/讨论帖：[图卷积有多强大?](#)，讨论了这类模型的一些局限性。我在本文末尾对Ferenc的[评论](#)写了简短评论。

大纲

- 神经网络模型图简要介绍

- 谱图卷积与图卷积网络 (GCN)
- 演示：用简单的一阶GCN模型进行图嵌入
- 作为Weisfeiler-Lehman算法的可微推广的GCN

如果你已经熟悉GCN和相关方法，建议直接学习[“嵌入空手道俱乐部网络”](#)。

图卷积网络有多强大？

近期文献

将成熟的神经模型如RNN或CNN推广到任意结构化的图是个挑战性问题。一些近期论文引入了针对特定问题的专业架构（例如 [Duvenaud 等](#)，NIPS 2015; [Li 等](#)，ICLR 2016; [Jain 等](#)，CVPR 2016），其他人则利用谱图论中已知的图卷积¹ ([Bruna 等](#)，ICLR 2014; [Henaff 等](#)，2015) 定义用于多层神经网络模型的参数化滤波器，类似于我们熟知和喜爱的“经典”CNN。

更近的研究重点是弥合快速启发式与缓慢启发式之间的差距²但更为原则性、幽灵式的方法。[Defferrard 等人](#)。（NIPS 2016）利用切比雪夫多项式在类似神经网络的模型中学习自由参数，近似谱域中的平滑滤波器。它们在常规领域（如MNIST）上取得了令人信服的结果，接近简单的二维CNN模型。

在[Kipf & Welling](#) (ICLR 2017) 中，我们采取了类似的方法，从谱图卷积框架出发，但引入了简化（后文会详细介绍），这些简化在许多情况下允许显著加快训练时间和更高的预测准确率，从而在多个基准图数据集上达到最先进的分类结果。

GCNs 第一部分：定义

目前，大多数图神经网络模型具有某种共通的通用架构。我将这些模型称为图卷积网络 (GCN)；卷积的，因为滤波器参数通常在图中的所有位置（或其子集，如 [Duvenaud 等](#)，NIPS 2015）共享。

对于这些模型，目标是学习图上信号/特征的函数 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 其输入为：

- 功能描述 x_i 对每个节点 i ；总结为 $N \times D$ 特征矩阵 X (N ：节点数， D ：输入特征数量)
- 图结构的矩阵形式代表性描述；通常以邻接矩阵的形式出现 A （或其某种功能）

并产生节点级输出 Z （一个 $N \times F$ 特征矩阵，其中 F 是每个节点输出特征的数量）。图级输出可以通过引入某种形式的池化操作来建模（参见例如 [Duvenaud 等](#)，NIPS 2015）。

每个神经网络层都可以写成非线性函数

$$H^{(l+1)} = f(H^{(l)}, A),$$

其中 $H^{(0)} = X$ 以及 $H^{(L)} = Z$ （或 z 对于图级输出）， L 即层数。具体模型的区别仅在于 $f(\cdot)$ ，被选定并参数化。

GCNs 第二部分：一个简单的例子

举个例子，我们考虑以下非常简单的层级传播规则形式：

$$f(H^{(l)}, A) = \sigma(AH^{(l)}W^{(l)}),$$

其中 $W^{(l)}$ 是 l -th 个神经网络层的权重矩阵和 $\sigma(\cdot)$ 是一个非线性激活函数，类似于 ReLU。尽管模型简单，但已经相当强大（稍后我们会详细说明）。

但首先，让我们解决这个简单模型的两个局限性：乘法 A 这意味着对于每个节点，我们求和所有邻居节点的所有特征向量，但不包括该节点本身（除非图中存在自环）。我们可以通过在图中强制自环来“修复”这个问题：只需将恒等矩阵加入到 A 。


第二个主要限制是 A 通常不归一化，因此乘法为 A 将完全改变特征向量的尺度（我们可以通过观察的特征值来理解 A ）。归一化 A 使得所有行的总和都为一，即 $D^{-1}A$ ，其中 D 是对角节点度矩阵，解决了这个问题。乘以 $D^{-1}A$ 现在对应于取邻近节点特征的平均值。在实际操作中，当我们使用对称归一化时，动力学变得更加有趣，即 $D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$ （因为这不再只是对邻近节点进行平均化。）结合这两个技巧，我们基本上得出了Kipf & Welling (ICLR 2017) 中引入的传播规则：

$$f(H^{(l)}, A) = \sigma \left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right),$$

其中 $\hat{A} = A + I$ ，其中 I 是单位矩阵， $\hat{D}$ 是 $\hat{A}$ 的对角节点度矩阵。

在下一节，我们将详细探讨这种模型如何在一个非常简单的示例图上工作：扎卡里的空手道俱乐部网络（记得查看[维基百科条目](#)！）。


GCNs 第三部分：嵌入空手道俱乐部网络



空手道俱乐部图中，颜色表示通过基于模块性聚类获得的社区（Brandes 等，2008）。

让我们看看我们的简单GCN模型（参见前一节或Kipf & Welling, ICLR 2017）在一个知名图数据集：Zachary的空手道俱乐部网络（见上图）上的工作原理。

我们取一个权重随机初始化的三层GCN。现在，即使在训练权重之前，我们只需插入图的邻接矩阵， $X = I$ （即单位矩阵，因为我们没有任何节点特征）映射到模型中。三层GCN现在在向前传递过程中执行三步传播，并有效地卷积了每个节点（所有最多3“跳”距离的节点）的三阶邻域。值得注意的是，该模型生成的这些节点嵌入与图的社区结构非常相似（见下图）。请记住，我们是完全随机初始化的负重，目前还没有进行任何训练更新！



空手道俱乐部网络中节点的GCN嵌入（随机权重）。

这听起来可能有些令人惊讶。最近一篇关于名为DeepWalk模型的论文（Perozzi等，KDD 2014）表明，他们可以在复杂的无监督训练程序中学习非常相似的嵌入方式。如何可能用我们简单的未训练GCN模型，几乎“免费”获得这样的嵌入？

我们可以通过将GCN模型解释为著名的Weisfeiler-Lehman图算法的广义、可微版本来解释这一点。（一维）Weisfeiler-Lehman 算法的工作原理如下³：

对所有节点 $v_i \in \mathcal{G}$ ：

- 获取功能⁴ $\{h_{v_j}\}$ 邻近节点的集合 $\{v_j\}$
- 更新节点功能 $h_{v_i} \leftarrow \text{哈希}\left(\sum_j h_{v_j}\right)$ ，其中哈希（是（理想情况下）一个单射哈希函数

重复 k 逐步或直到收敛。

实际上，Weisfeiler-Lehman 算法为大多数图分配一组独特的特征。这意味着每个节点都会被分配一个特征，唯一描述其在图中的角色。例外是高度规律的图，比如网格、链状图等。对于大多数不规则图，这种特征赋赋可以用来检查图同构（即两个图是否相同，直到节点置换）。

回到我们的图卷积层传播规则（现在是向量形式）：

$$h_{v_i}^{(l+1)} = \sigma \left(\sum_j \frac{1}{c_{ij}} h_{v_j}^{(l)} W^{(l)} \right),$$

其中 j 索引的邻近节点 v_j ， c_{ij} 是边的归一化常数 (v_i, v_j) 该矩阵源自对称归一化邻接矩阵 $D^{-\frac{1}{2}} A D^{-\frac{1}{2}}$ 在我们的GCN模型中。我们现在看到，这个传播规则可以解释为一个可微且参数化的（其中 $W^{(l)}$ ）是原始Weisfeiler-Lehman算法中使用的哈希函数的变体。如果我们现在选择一个合适的非线性矩阵，并将随机权重矩阵初始化使其正交（或使用Glorot和Bengio, AISTATS 2010中的初始化），该更新规则在实际中变得稳定（也得益于通过的归一化 c_{ij} ），我们发现了有意义的平滑嵌入，可以将距离解释为局部图结构的（不）相似性！

GCNs 第四部分：半监督学习

由于模型中的一切都是可微且参数化的，我们可以添加一些标签，训练模型并观察嵌入的响应。我们可以使用Kipf & Welling (ICLR 2017) 中引入的GCN半监督学习算法。我们只需为每个类别/社区标记一个节点（下面视频中重点标出的节点），然后开始训练几次迭代⁵：

0:00 / 0:06

半监督分类，GCNs：300次训练迭代，每类单标签的潜空间动力学。标记节点会被高亮显示。

注意，模型直接产生一个二维潜在空间，我们可以立即可视化。我们观察到，三层GCN模型能够线性区分群落，每个类别只给出一个标记的实例。这是一个相当显著的结果，因为模型未对节点进行特征描述。同时，*可以提供初始节点特征*，这正是我们在论文 ([Kipf & Welling, ICLR 2017](#)) 中描述的实验中所做的，以在多个图数据集上实现最先进的分类结果。

结论

关于这一主题的研究才刚刚开始。过去几个月见证了令人振奋的发展，但到目前为止，我们可能只是对这类模型的皮毛。目前尚待观察如何将图上的神经网络进一步应用于特定类型的问题，例如在有向图或关系图上的学习，以及如何利用学习后的图嵌入进行后续任务等。这份清单绝非详尽，我预计不久的将来还会有更多有趣的应用和扩展出现。如果你有任何令人兴奋的想法或问题，欢迎在下方评论告诉我！

感谢以下人员：

Max Welling、Taco Cohen、Chris Louizos 和 Karen Ullrich（关于论文和这篇博客文章的多项讨论和反馈）。另外，我要感谢Ferenc Huszar指出这类模型的一些缺点。

关于完整性的说明

这篇博客文章绝非对神经网络图领域的全面综述。为了让这篇文章更易读，并赋予它连贯的故事线，我省略了不少近期和较早的论文。不过，如果你想深入探讨这个话题，全面了解现有情况和已尝试过的方案，我这里提到的论文依然是一个很好的起点。

引用

如果你想在自己的工作中使用其中一些，可以引用我们关于图卷积网络的[论文](#)：

```
@article{kipf2016semi,  
  title={Semi-Supervised Classification with Graph Convolutional Networks},  
  author={Kipf, Thomas N and Welling, Max},  
  journal={arXiv preprint arXiv:1609.02907},
```

```
year={2016}
}
```

源代码

我们已在GitHub上发布了图卷积网络的代码：<https://github.com/tkipf/gcn>。

你可以在[推特](#)上关注我，获取未来的更新。

推特 0 分享

正则图的问题

接下来，我将简要评论Ferenc Huszar最近的博客文章《[图卷积有多强大？](#)》中的观点，该文章对这里讨论的一些模型持稍显负面的看法。费伦茨考虑正则图的特例。他正确指出，图卷积网络（如本文介绍）相比专门为该领域设计的模型（如“经典”二维CNN用于图像）相比，在常规图上的操作相当简单。确实需要注意的是，当前适用于任意结构图的图神经网络模型，在应用于常规图（如网格、链、全连通图等）时通常存在某种缺陷。例如，局部光谱处理（如Defferrard等，NIPS 2016）可归还为旋转对称滤波器，且永远无法模拟“经典”二维CNN在网格上的操作（排除边界效应）。同样，Weisfeiler-Lehman 算法在正则图上也不会收敛。这告诉我们，在评估特定图神经网络模型的实用性时，我们应该超越常规网格，因为设计任意图模型时必须做出特定的权衡（但当然，提醒人们这些权衡很重要）——也就是说，当然，除非我们最终能提出一个普遍强大的模型。

1. A spectral graph convolution is defined as the multiplication of a signal with a filter in the Fourier space of a graph. A graph Fourier transform is defined as the multiplication of a graph signal X (i.e. feature vectors for every node) with the eigenvector matrix U of the graph Laplacian L . The (normalized) graph Laplacian can be easily computed from the symmetrically normalized graph adjacency matrix $\tilde{A}$: $L = I - \tilde{A}$.↩
2. Using a spectral approach comes at a price: Filters have to be defined in Fourier space and a graph Fourier transform is expensive to compute (it requires multiplication of node features with the eigenvector matrix of the graph Laplacian, which is a $O(N^2)$ operation for a graph with N nodes; computing the eigenvector matrix in the first place is even more expensive).↩
3. I'm simplifying things here. For an extensive mathematical discussion of the Weisfeiler-Lehman algorithm, have a look at the paper by Douglas (2011).↩
4. Node features for the Weisfeiler-Lehman algorithm are typically chosen as scalar integers and are often referred to as colors.↩
5. As we don't anneal the learning rate in this example, things become quite "jiggly" once the model has converged to a good solution.↩

GET IN TOUCH



